ETUDE DE CAS / RISQUES NATURELS & DATA SCIENCE

Peut-on estimer le temps avant une éruption à partir de signaux sismiques ?

Du besoin de surveillance à une prédiction statistique : ce que les données peuvent montrer, et ce qu'elles ne peuvent pas garantir.

Un volcan ne dispose pas d'un compte à rebours. Pourtant, il produit des signaux : vibrations, mouvements du sol et manifestations d'une activité interne qui peuvent évoluer avant certains événements éruptifs. Ces informations peuvent-elles aider à estimer le temps qui sépare une observation de la prochaine éruption ?

Cette interrogation motive le projet. L'idée n'est pas de remplacer le jugement des volcanologues par un chiffre, mais d'examiner si l'apprentissage automatique peut découvrir, dans des mesures sismiques, des relations utiles avec le délai précédant une éruption. Pour un acteur de la surveillance, l'enjeu serait de disposer d'un **indicateur complémentaire** ; pour le Data Scientist, de comprendre à quel point cet indicateur est fiable.

Une promesse séduisante, mais une exigence forte

Une prédiction peut être globalement précise et néanmoins se tromper dans les situations où le temps restant est le plus court. C'est pourquoi ce rapport suit le problème de bout en bout : formuler un besoin métier, rendre les signaux exploitables, entraîner un modèle, puis examiner non seulement ses scores, mais aussi la manière dont il se trompe.

> **Question directrice.** Les caractéristiques d'un signal sismique permettent-elles d'estimer le délai avant une éruption, et dans quelle mesure cette estimation pourrait-elle être interprétée de façon responsable ?

Le terrain de l'étude

Les données proviennent de la compétition *INGV – Volcanic Eruption Prediction*. Chaque observation est un segment de mesures issues de dix capteurs sismiques, accompagné, pour l'apprentissage, d'une cible numérique : **time_to_eruption**. Le travail présente une **simulation exploratoire**, et non un outil d'alerte ou de décision d'évacuation.

01 / COMPRENDRE LE PROBLEME

Du besoin métier à une tâche de régression

La surveillance volcanologique mobilise plusieurs types de mesures et une expertise scientifique. Les signaux sismiques en constituent une source précieuse, mais leur interprétation demeure complexe : une modification du signal ne correspond pas automatiquement à une éruption imminente.

Ce que l'on cherche réellement à prédire

Le projet ne cherche pas à répondre à la question « faut-il évacuer ? ». Il pose une question beaucoup plus étroite et vérifiable : **quel est le temps restant avant la prochaine éruption pour un segment donné ?** La réponse attendue est une valeur continue, ce qui fait du problème une tâche de **régression supervisée**.

Ce qui entre dans le modèle	Ce que le modèle apprend à produire
Dix séries de mesures sismiques, décrites par des caractéristiques numériques	Une estimation de *time_to_eruption* pour le segment observé

De la donnée brute à une observation exploitable

Le jeu étudié comprend **4 431 segments étiquetés**. Chaque segment correspond à dix minutes de mesures sur dix capteurs. Les données sont enregistrées dans des fichiers distincts, reliés à la cible par **segment_id**. Cet identifiant sert aux jointures et aux vérifications ; il n'est jamais utilisé comme variable de prédiction.

Avant tout entraînement, le notebook contrôle la correspondance entre fichiers et métadonnées, l'unicité des identifiants et les valeurs non finies. Certaines statistiques impossibles à calculer restent manquantes plutôt que d'être remplacées par une valeur arbitraire. Un mécanisme de cache évite de relire les milliers de fichiers à chaque essai.

> **Enjeu métier :** un mauvais rattachement entre les mesures et le temps avant éruption rendrait l'apprentissage trompeur, même si l'algorithme était techniquement correct. La qualité de la préparation est donc une condition de crédibilité du résultat.

Une limite présente dès le départ

Le jeu de compétition fournit une représentation partielle du phénomène. Il ne reconstitue pas l'ensemble du contexte physique d'un volcan, ni toutes les observations qu'examinerait un service de surveillance. Cette restriction orientera l'interprétation finale : nous testons la **valeur prédictive de ces données**, non la possibilité d'anticiper de manière certaine un événement réel.

02 / CONSTRUIRE L'INFORMATION

Faire parler les signaux sans les complexifier

Un signal brut est une succession de milliers d'amplitudes. Un modèle d'arbres de décision n'a pas besoin de recevoir chacune de ces valeurs : il peut apprendre à partir de résumés soigneusement choisis. Le **feature engineering** consiste précisément à transformer les séries temporelles en variables numériques compréhensibles et comparables.

Famille	Nombre	Ce qu'elle décrit
Statistiques descriptives	60	Amplitude, dispersion et valeurs extrêmes
Structure temporelle	50	Evolution à l'intérieur du segment et dépendances
Contenu spectral	20	Répartition de la puissance selon les fréquences
Qualité des données	10	Part de mesures absentes pour chaque capteur
Variables globales	3	Vue synthétique entre capteurs
Total	**143**	**Une ligne descriptive par segment**

L'amplitude : le niveau et la forme des vibrations

La moyenne, l'écart-type et le **RMS** décrivent le niveau et les variations du signal. Le MAD, la kurtosis et le 95e percentile des amplitudes absolues complètent cette lecture en caractérisant la dispersion et les valeurs élevées. Le RMS, par exemple, résume l'amplitude quadratique des mesures : plus il est élevé, plus le signal possède, dans cette représentation, une amplitude quadratique importante.

Le temps : comment le signal évolue

Quatre RMS sont calculés sur des quarts successifs du segment. Cela permet au modèle de distinguer deux enregistrements d'amplitude globale comparable mais d'évolution différente. Une **autocorrélation au retard 100** mesure également la ressemblance statistique du signal avec lui-même après un décalage de 100 échantillons. Ce choix est un paramètre de description, et non une durée physique de 100 secondes.

La fréquence : quelles oscillations composent le signal ?

La méthode de **Welch** estime la densité spectrale de puissance en moyennant les spectres de fenêtres partiellement chevauchantes. Nous en tirons deux indices par capteur : le **centroïde spectral** (centre de gravité des fréquences pondérées par la puissance) et la **fraction de puissance basse fréquence**. Le calcul utilisant une fréquence normalisée, ces grandeurs s'expriment en cycles par échantillon, pas directement en hertz.

> **Le lien avec le métier.** Ces 143 variables traduisent un signal difficile à parcourir en une description que l'on peut étudier et expliquer. Elles sont des *hypothèses d'information prédictive* ; aucune n'est, à elle seule, un précurseur éruptif validé.

03 / APPRENDRE ET EVALUER

Un modèle performant ne suffit pas : il faut pouvoir le vérifier

Une fois chaque segment représenté par 143 variables, nous cherchons à apprendre la relation entre ces descriptions et **time_to_eruption**. Deux algorithmes de gradient boosting sur arbres ont été comparés : **XGBoost** et **LightGBM**. Ces méthodes construisent successivement des arbres afin de capturer des relations non linéaires entre les variables et la cible.

Pourquoi deux modèles ?

Ils appartiennent à une même famille, mais leurs stratégies de croissance des arbres diffèrent. Les comparer sur les mêmes données permet de justifier le choix final, sans multiplier les architectures. Une **baseline médiane** sert de référence : elle prédit toujours la médiane de la cible et montre ce que vaut l'ajout réel d'information sismique.

Comment éviter une sélection trompeuse ?

Les données étiquetées sont séparées en un ensemble de développement (80 %) et un **holdout** d'évaluation (20 %, soit 887 segments). Dans la partie développement, une validation croisée à **cinq folds** sert à rechercher les hyperparamètres. Dix combinaisons sont testées pour chaque algorithme avec les mêmes partitions et la même métrique de comparaison.

Moment	Rôle	Critère
Entraînement	Ajuster les arbres	Perte quadratique
Validation croisée	Choisir les hyperparamètres et le modèle	MAE minimale
Holdout	Décrire la performance finale	MAE, RMSE, R^2 et erreurs

Pourquoi entraîner avec une perte quadratique mais sélectionner avec la MAE ?

La perte quadratique donne davantage de poids aux erreurs de grande amplitude pendant l'apprentissage. La **MAE**, elle, mesure l'écart absolu moyen entre la valeur prédite et la valeur réelle. Il est cohérent d'utiliser l'une pour construire les arbres et l'autre pour déterminer quelle configuration prédit le mieux selon le critère retenu.

> **Précaution méthodologique.** Le découpage est aléatoire. Si plusieurs segments sont liés à un même épisode éruptif, ils peuvent être présents à la fois dans le développement et l'évaluation. Le protocole ne démontre donc pas la généralisation à de nouvelles éruptions indépendantes.

04 / OBSERVER LES RESULTATS

XGBoost apprend nettement mieux que la référence naïve

Les deux algorithmes sont évalués sur les mêmes cinq folds et avec dix configurations testées. Dans cette expérience, **XGBoost** présente une erreur absolue moyenne plus faible et est retenu pour l'analyse du holdout.

Modèle	MAE en validation croisée	Ecart-type entre folds
XGBoost	**3,38 M**	64 507
LightGBM	3,76 M	98 158

L'écart de MAE est d'environ **376 000 unités**, soit près de 10 % de la MAE obtenue par LightGBM. Cette comparaison décrit la recherche effectuée ; elle ne prouve pas que XGBoost soit toujours supérieur.

Ce qui se passe sur 887 observations mises de côté

MAE XGBoost	MAE baseline	RMSE	R^2
3,14 M	11,83 M	4,31 M	0,8999

Par rapport à la prédiction constante de la médiane, la MAE diminue de **73,46 %**. Le R^2 de 0,8999 montre une forte adéquation globale sur cette partition. Cependant, la RMSE supérieure à la MAE rappelle que certaines erreurs individuelles restent substantielles.

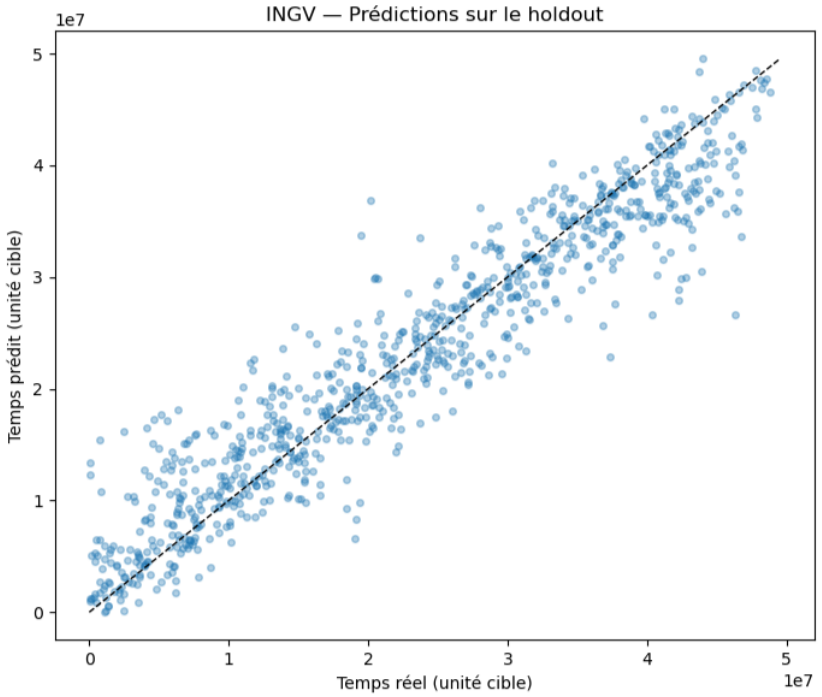


Figure 1. Temps réel et temps prédit sur le holdout (capture du notebook). La diagonale pointillée représente la prédiction parfaite. Les points restent dispersés de part et d'autre, en particulier aux extrêmes.

05 / COMPRENDRE LES ERREURS

Le principal enseignement apparaît aux extrêmes

Pour comprendre l'utilité réelle d'une estimation, nous avons regroupé les observations du holdout selon leur **temps véritable avant éruption**. Quatre quartiles, d'effectifs presque égaux, mettent en évidence une structure d'erreurs que les indicateurs globaux ne montrent pas.

Groupe	Réel moyen	Prédit moyen	Biais	MAE
Q1 · temps courts	5,79 M	8,32 M	**+2,53 M**	3,27 M
Q2	16,82 M	17,65 M	+0,84 M	3,07 M
Q3	28,84 M	28,28 M	−0,57 M	2,56 M
Q4 · temps longs	41,06 M	37,99 M	**−3,07 M**	3,67 M

Lecture : biais = temps prédit − temps réel. Un biais positif signifie que le modèle annonce un délai plus long que celui effectivement observé. Chiffres arrondis en millions d'unités de la cible.

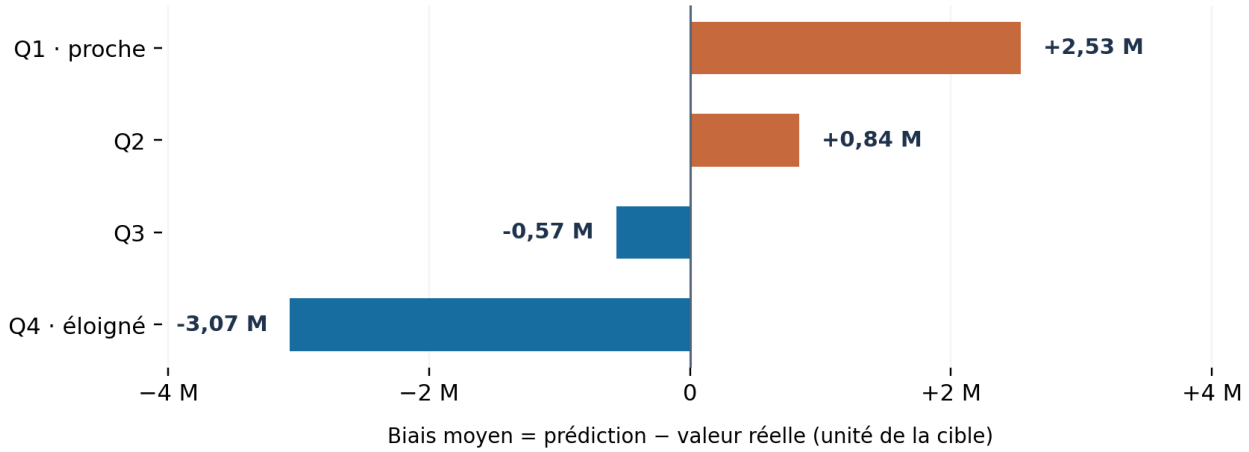


Figure 2. Biais moyen selon les quartiles du temps réel. Valeurs calculées à partir du tableau de résultats communiqué ; aucune observation individuelle n'a été reconstituée.

Une tendance vers les valeurs centrales

Pour les éruptions les plus proches (Q1), le modèle **surestime** le délai en moyenne de 2,53 M. Pour les plus lointaines (Q4), il le **sous-estime** de 3,07 M. Les prédictions paraissent ainsi moins extrêmes que les valeurs réelles : ce profil est compatible avec une **régression vers la moyenne**.

Cela peut provenir d'une information sismique insuffisante pour distinguer certains délais, du bruit des observations ou de la façon dont la perte quadratique favorise une estimation centrale. Il faut toutefois rester prudent : des groupes définis d'après la vraie cible peuvent montrer ce profil même pour un modèle statistiquement raisonnable. Ce tableau ne démontre donc pas, à lui seul, un défaut de calibration.

06 / REVENIR AU BESOIN METIER

Une estimation utile à discuter, pas un délai à suivre aveuglément

La lecture métier change le sens des erreurs. **Surestimer le temps restant** signifie annoncer une échéance plus lointaine que la réalité et pourrait donner une impression excessive du délai disponible. Une sous-estimation annonce, à l'inverse, une échéance trop proche.

La MAE traite symétriquement ces erreurs. Elle reste utile pour comparer les modèles, mais ne résume pas leurs conséquences potentielles. Ce projet ne définit aucun seuil d'alerte validé.

Pourquoi ne pas corriger simplement le biais observé ?

Le premier quartile est défini par le temps *réel*, inconnu pour une nouvelle observation. Soustraire 2,53 M aux prédictions supposées « proches » exigerait donc déjà de connaître la réponse. Une éventuelle calibration devrait être conçue hors entraînement puis validée sur des données indépendantes.

Conclusion : ce que l'étude démontre — et ce qu'elle laisse ouvert

Cette étude transforme des enregistrements sismiques en un **modèle de régression interprétable dans sa démarche** : contrôles de qualité, 143 caractéristiques, deux algorithmes comparés et évaluation critique. XGBoost est retenu avec une MAE de 3,14 M sur le holdout, contre 11,83 M pour la baseline.

Le score ne prouve pourtant pas la fiabilité métier : les délais courts sont souvent surestimés en moyenne, la validation aléatoire ne mesure pas clairement la généralisation à de nouveaux épisodes, et les prédictions n'expriment pas leur incertitude individuelle.

La priorité future serait de valider sur des **épisodes éruptifs indépendants**, puis d'étudier l'incertitude et les erreurs dans les situations critiques, plutôt que de multiplier les modèles.

> **Conclusion métier.** L'intérêt du modèle est **exploratoire et analytique**. Aucun résultat de cette étude ne valide son usage pour déclencher une alerte ou une évacuation.

SOURCES ET TRAÇABILITE

Résultats : captures du notebook transmises le 23 octobre 2026 (comparaison XGBoost/LightGBM, métriques du holdout, graphique réel/prédit), tableau des quartiles et code d'extraction du projet.

Données et contexte : INGV – Volcanic Eruption Prediction (Kaggle). Méthode spectrale : documentation SciPy, scipy.signal.welch. Les unités de time_to_eruption sont conservées sans conversion physique non vérifiée.